

# Data Professional Salary Survey Analysis

Raport z EDA, przygotowania danych bez leakage, regresji, klasyfikacji i klasteryzacji.

Preprocessing pozostaje wewnątrz Pipeline; OtherDatabases jest kodowane jako multi-label; Counter oraz pola identyfikacyjne są wykluczone; techniczna klasa Not Asked nie uczestniczy w klasyfikacji.

Wynagrodzenia są nominalne. Regresja wykorzystuje log1p celu, ale MAE i RMSE raportuje w USD. Cały raport mieści się w wymaganym zakresie 10-20 stron.

# Najważniejsze wyniki i zakres zastosowania

Regresja: XGBoost osiąga test MAE około 19 tys. USD. Wynik jest użyteczny jako orientacyjna estymacja na poziomie grup, lecz nie usuwa niepewności indywidualnej.

Klasyfikacja: test Macro F1 i balanced accuracy wynoszą około 0,25. Model pozwala na eksploracyjne rozróżnianie planów zawodowych, lecz jego jakość jest zbyt niska do decyzji kadrowych lub automatycznej klasyfikacji produkcyjnej.

Klasteryzacja: K-Means daje słabą, ale opisywalną segmentację. DBSCAN nie potwierdził stabilnych klastrów, dlatego wyniki mają charakter badawczy, a nie operacyjny.

Walidacja po tuningu jest non-nested CV: 3-fold CV wybiera hiperparametry, a 5-fold CV ponownie ocenia ustaloną konfigurację na tym samym train. Może to lekko zawyżać CV; niezależny test pozostaje oceną końcową.

# Podsumowanie jakości modeli

## Regresja [USD]

| Model                 | CV MAE $\pm$ SD  | Test MAE | Test RMSE | Test R <sup>2</sup> (log) |
|-----------------------|------------------|----------|-----------|---------------------------|
| XGBoost tuned         | 19,733 $\pm$ 617 | 19,228   | 29,756    | 0.630                     |
| XGBoost default       | 20,102 $\pm$ 672 | 19,435   | 29,827    | 0.619                     |
| Random Forest default | 20,302 $\pm$ 589 | 19,626   | 30,277    | 0.615                     |
| Ridge default         | 20,896 $\pm$ 640 | 20,616   | 31,198    | 0.598                     |

## Klasyfikacja

| Model                       | CV Macro F1 $\pm$ SD | Test Macro F1 | Balanced accuracy |
|-----------------------------|----------------------|---------------|-------------------|
| LightGBM tuned              | 0.251 $\pm$ 0.009    | 0.250         | 0.255             |
| LightGBM default            | 0.244 $\pm$ 0.005    | 0.245         | 0.263             |
| Logistic Regression default | 0.228 $\pm$ 0.003    | 0.223         | 0.265             |
| Random Forest default       | 0.228 $\pm$ 0.011    | 0.236         | 0.239             |

# Szczegółowe wyniki

## Klasyfikacja: metryki per class


| Class                                            | Precision | Recall | F1    | Support |
|--------------------------------------------------|-----------|--------|-------|---------|
| Change both employers and roles                  | 0.109     | 0.126  | 0.117 | 183     |
| Prefer not to say                                | 0.123     | 0.154  | 0.137 | 195     |
| Stay with the same employer, but<br>change roles | 0.159     | 0.205  | 0.179 | 258     |
| Stay with the same employer, same<br>role        | 0.687     | 0.581  | 0.630 | 1,479   |
| Stay with the same role, but<br>change employers | 0.166     | 0.211  | 0.186 | 280     |
| macro avg                                        | 0.249     | 0.255  | 0.250 | 2,395   |
| weighted avg                                     | 0.479     | 0.428  | 0.450 | 2,395   |

## K-Means: skrócone profile klastrów

| Cluster | N     | Share | Median salary | Job years | DB years | Country       |
|---------|-------|-------|---------------|-----------|----------|---------------|
| 0       | 6,463 | 43.5% | \$79,000      | 7.0       | 10.0     | United States |
| 1       | 8,406 | 56.5% | \$105,000     | 6.0       | 12.0     | United States |


# EDA: jakość, rozkłady i anomalie

EmploymentStatus



Braki zależą od statusu zatrudnienia;  
imputacja musi być uczona na train.

Rozkłady wszystkich zmiennych liczbowych




Salary pokazano w log-scale, staż w zakresie  
0-60, a Counter pominięto.

SalaryUSD

Staż z bazą danych


Staż w typie pracy



Anomalie są widoczne osobno i nie zniekształcają wykresów głównych.


# EDA: rozkład wynagrodzenia i czas

Rozkład SalaryUSD — skala nominalna




Surowe SalaryUSD jest silnie prawostronnie skośne.

Rozkład log1p(SalaryUSD)




log1p stabilizuje rozkład celu regresji.

Mediana nominalnego SalaryUSD według roku ankiety



Zmiana w czasie uzasadnia zachowanie Survey Year i temporal split.


# EDA: determinanty wynagrodzenia



Kraj wyraźnie różnicuje medianę wynagrodzenia.




Stanowisko jest ważne, lecz grupy mocno się nakładają.




Zależność stażu i płacy jest dodatnia, nieliniowa i rozproszona.


# EDA: doświadczenie i plany zawodowe



Poziomy doświadczenia różnią mediany, ale nie separują grup.





Plany zawodowe zależą od statusu zatrudnienia.



Nierównowaga klas uzasadnia Macro F1 zamiast accuracy.



# EDA: kategorie i zależności



Rzadkie kategorie są grupowane wyłącznie na train.

OtherDatabases wymaga kodowania multi-label.




Słabe korelacje parami nie wykluczają nieliniowych interakcji.


# Modele: przegląd i regresja

Zbiorcze porównanie modeli

Regresja — test MAE [USD]




Klasyfikacja — test Macro F1




Regresję i klasyfikację oceniamy w ich własnych metrykach.

Porównanie modeli regresyjnych — MAE w nominalnych USD




Model wybrano według CV MAE; test jest oceną końcową.

Permutation importance — najlepszy model regresyjny




Ważności są predykcyjne, nie przyczynowe.


# Modele: klasyfikacja



Macro F1 około 0,25 oznacza niską jakość praktyczną.




Rzadkie klasy mają niski recall i często są mylone.




Model nadaje się do eksploracji, nie decyzji kadrowych.

# Klasteryzacja: redukcja wymiaru i wybór k




Dwa komponenty służą wyłącznie do wizualizacji.




Niskie silhouette wskazuje słabą strukturę klastrow.

# Klasteryzacja: mapa i profile



K-Means uczono na 20 komponentach; wykres jest tylko rzutem 2D.



Profile są opisowe i nie stanowią stabilnych segmentów operacyjnych.

# Ograniczenia i wnioski końcowe

Dane są samoopisowe i mogą nie reprezentować całego rynku; analiza nie uzasadnia wniosków przyczynowych. Wynagrodzenia nie są skorygowane o inflację, kursy ani PPP.

Losowy split miesza lata, dlatego regresja zawiera także temporal holdout. Test nie uczestniczy w dopasowaniu preprocessingu, wyborze cech ani hiperparametrów.

Niska jakość klasyfikacji i słaby silhouette wykluczają zastosowania produkcyjne bez nowych cech, danych zewnętrznych oraz prospektywnej walidacji.

Najbardziej wiarygodnym rezultatem jest pipeline regresyjny; klasyfikację i klasteryzację należy traktować jako analizy eksploracyjne.