

Data Professional Salary Survey Analysis

Raport z eksploracyjnej analizy danych, przygotowania danych bez leakage, regresji, klasyfikacji i klasteryzacji.

Najważniejsze korekty metodologiczne: preprocessing wewnątrz Pipeline po train/test split; multi-label encoding pola OtherDatabases; usunięcie stałej Counter; zachowanie Survey Year; wykluczenie technicznej klasy Not Asked z klasyfikacji.

Metryki regresji w USD są liczone po odwrotnej transformacji $\exp m1$. $R2_log$ dotyczy przestrzeni $\log_{1p}(\text{SalaryUSD})$. Kwoty są nominalne i nie są skorygowane o inflację ani parytet siły nabywczej.

Regresja: train vs CV vs test

model	train_MAE_USD	CV_MAE_USD_mean	CV_MAE_USD_std	test_MAE_USD	test_RMSE_USD	train_R2_log	CV_R2_log_mean	CV_R2_log_std	test_R2_log
XGBoost tuned	15846.706	19732.642	616.761	19228.102	29756.14	0.777	0.606	0.013	0.63
XGBoost default	15759.927	20102.151	671.783	19435.244	29826.889	0.779	0.596	0.014	0.619
Random Forest default	9928.187	20302.283	588.969	19626.38	30277.048	0.892	0.586	0.014	0.615
Ridge default	20665.782	20895.785	639.775	20615.684	31198.008	0.58	0.571	0.017	0.598

Klasyfikacja: train vs CV vs test

model	train_balanced_accuracy	CV_balanced_accuracy	CV_balanced_accuracy	test_balanced_accuracy	train_macro_F1	CV_macro_F1_mean	CV_macro_F1_std	test_macro_F1
LightGBM tuned	0.944	0.253	0.009	0.255	0.852	0.251	0.009	0.25
LightGBM default	0.83	0.26	0.007	0.263	0.687	0.244	0.005	0.245
Logistic Regression default	0.328	0.269	0.007	0.265	0.272	0.228	0.003	0.223
Random Forest default	0.997	0.236	0.007	0.239	0.992	0.228	0.011	0.236

Klasyfikacja: metryki per class


Unnamed: 0	precision	recall	f1-score	support
Change both employers and roles	0.109	0.126	0.117	183.0
Prefer not to say	0.123	0.154	0.137	195.0
with the same employer, but change roles	0.159	0.205	0.179	258.0
stay with the same employer, same role	0.687	0.581	0.63	1479.0
with the same role, but change employer	0.166	0.211	0.186	280.0
accuracy	0.428	0.428	0.428	0.428
macro avg	0.249	0.255	0.25	2395.0
weighted avg	0.479	0.428	0.45	2395.0

Profile klastrów

Cluster_KMeans	size	median_salary	median_job_years	median_database_years	dominant_country	dominant_job	dominant_employe	share_pct
0	6463	79000.0	7.0	10.0	DBA (Production)	Focus - build & troubles	Full time employee	43.466
1	8406	105000.0	6.0	DBA (Generalists)	Splits time evenly between writing & tuning queries	Full time employee		56.534



cluster 01 svd explained variance

TruncatedSVD — skumulowana explained variance




Interpretacja: Dwa komponenty nie zachowują całej struktury; służą wyłącznie do wizualizacji.

cluster 02 k selection





Interpretacja: Elbow i silhouette zastępują arbitralny wybór liczby klastrów.

cluster 03 kmeans 2d




Interpretacja: Wykres jest rzutem 2D, podczas gdy klasteryzacja wykorzystuje 20 komponentów.

cluster 04 profiles



Interpretacja: Profile według kraju, roli, stażu i pensji nadają segmentom interpretację biznesową.


eda 01 missingness by employment




Interpretacja: Braki zależą od statusu zatrudnienia; imputacja i wskaźniki braków muszą być uczone na train.

eda 02 all numeric distributions


Rozkłady wszystkich zmiennych liczbowych



Interpretacja: Skośność, długie ogony i stała Counter uzasadniają transformację celu oraz reguły jakości.



Interpretacja: SalaryUSD jest silnie prawostronnie skośne; wysokie wartości wpływają na błędy w USD.




Interpretacja: $\log_{1p}$ stabilizuje rozkład celu; wyniki biznesowe są następnie przeliczane z powrotem na USD.

eda 05 anomalies boxplots




Interpretacja: Odstające wynagrodzenia są analizowane, a staż powyżej 60 lat jest traktowany jako błąd jakości.




Interpretacja: Kraj silnie różnicuje medianę i rozrzut wynagrodzeń i jest istotną cechą modelu.

eda 07 salary top jobs




Interpretacja: Stanowisko wpływa na wynagrodzenie, lecz nakładanie grup wymaga analizy wielowymiarowej.



Interpretacja: Zmiana mediany w czasie uzasadnia zachowanie Survey Year i dodatkowy temporal split.




Interpretacja: Zależność stażu i wynagrodzenia jest dodatnia, lecz nieliniowa i silnie rozproszona.




Interpretacja: Mediana rośnie z doświadczeniem, ale grupy nakładają się; potrzebne są także pozostałe cechy.


eda 11 career by employment



Interpretacja: Struktura planów zależy od zatrudnienia; Not Asked pozostaje artefaktem ankiety 2017.




Interpretacja: Plany różnią się według doświadczenia, a nierównowaga klas wymaga Macro F1.




eda 14 category frequencies

Najczęstsze kategorie: PrimaryDatabase



DBA (General - splits time evenly between writing & tuning queries AND building & troubleshooting servers)

Najczęstsze kategorie: JobTitle



Interpretacja: Nierówne częstości uzasadniają train-fitted grouping rzadkich kategorii.


eda 15 spearman correlations




Interpretacja: Słabe korelacje parami nie wykluczają nieliniowości i interakcji wykorzystywanych przez drzewa.

Zbiorcze porównanie modeli

Regresja — test MAE [USD], mniej = lepiej




Klasyfikacja — test Macro F1, więcej = lepiej




Interpretacja: Panele zestawiają modele w ramach właściwych metryk; MAE i Macro F1 nie są porównywane bezpośrednio.

model 01 regression comparison




Interpretacja: Train, CV i test pokazują jakość generalizacji; MAE jest raportowane w nominalnych USD.

model 02 regression importance




Interpretacja: Permutation importance mierzy wpływ predykcyjny całych surowych kolumn, nie przyczynowość.

model 03 classification comparison




Interpretacja: Macro F1 porównuje modele bez sztucznej klasy Not Asked i nadaje klasom równą wagę.

model 04 classification confusion matrix



Interpretacja: Znormalizowana macierz pokazuje recall oraz pary klas najczęściej ze sobą mylone.

model 05 classification importance



Interpretacja: Ważności opisują predykcję planów zawodowych po usunięciu artefaktu 2017.

Ograniczenia i zagrożenia trafności

Dane są samoopisowe i pochodzą z próby ankietowej, która może nie reprezentować całego rynku. Analiza nie uzasadnia wniosków przyczynowych.

Losowy split miesza lata 2017–2026; dlatego regresja zawiera dodatkowy temporal split. Survey Year pozostaje cechą, jednak wynagrodzenia są nominalne i bez korekty inflacyjnej.

Not Asked pochodzi wyłącznie z 2017 roku i nie jest prawdziwą kategorią planów zawodowych. Wyniki głównej klasyfikacji dotyczą wyłącznie respondentów, którym zadano pytanie.

Dobór reguł jakości, reprezentacji multi-label, hiperparametrów SVD oraz algorytmów wpływa na rezultaty. DBSCAN z jednym klastrem należy traktować jako wynik negatywny.

Test nie uczestniczy w dopasowaniu preprocessingu ani wyborze hiperparametrów; ostateczne metryki testowe nie powinny być dalej optymalizowane.